Descriptores de imágenes I

Visión por Computador, curso 2024-2025

Silvia Martín Suazo, silvia.martin@u-tad.com

9 de octubre de 2024

U-tad | Centro Universitario de Tecnología y Arte Digital

Introducción

Descripción de imágenes y reconocimiento de objetos

La descripción de imágenes es un proceso por el cual se consiguen extraer las características más importantes que componen una escena, como por ejemplo qué elementos la componen, en qué posición, etc.

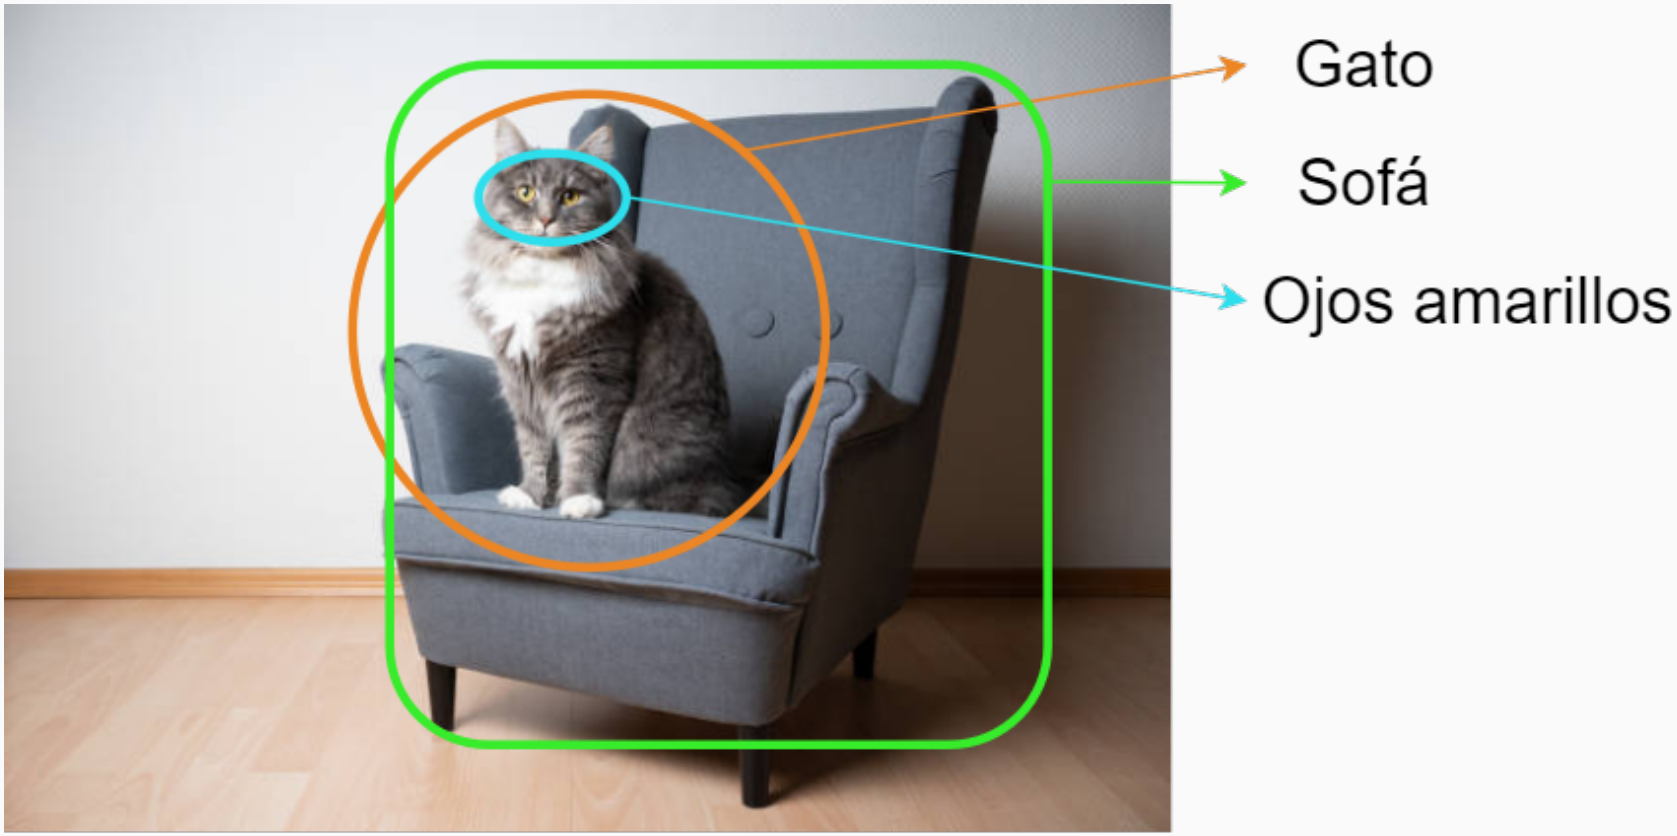

Descripción de imágenes en el procesado de imágenes

La descripción de imágenes forma parte de uno de los primero pasos a la hora de procesar imágenes.

Dentro de la metodología para procesar imágenes, a través de las descripción se consiguen identificar puntos de interés que identifican la composición de una imagen.

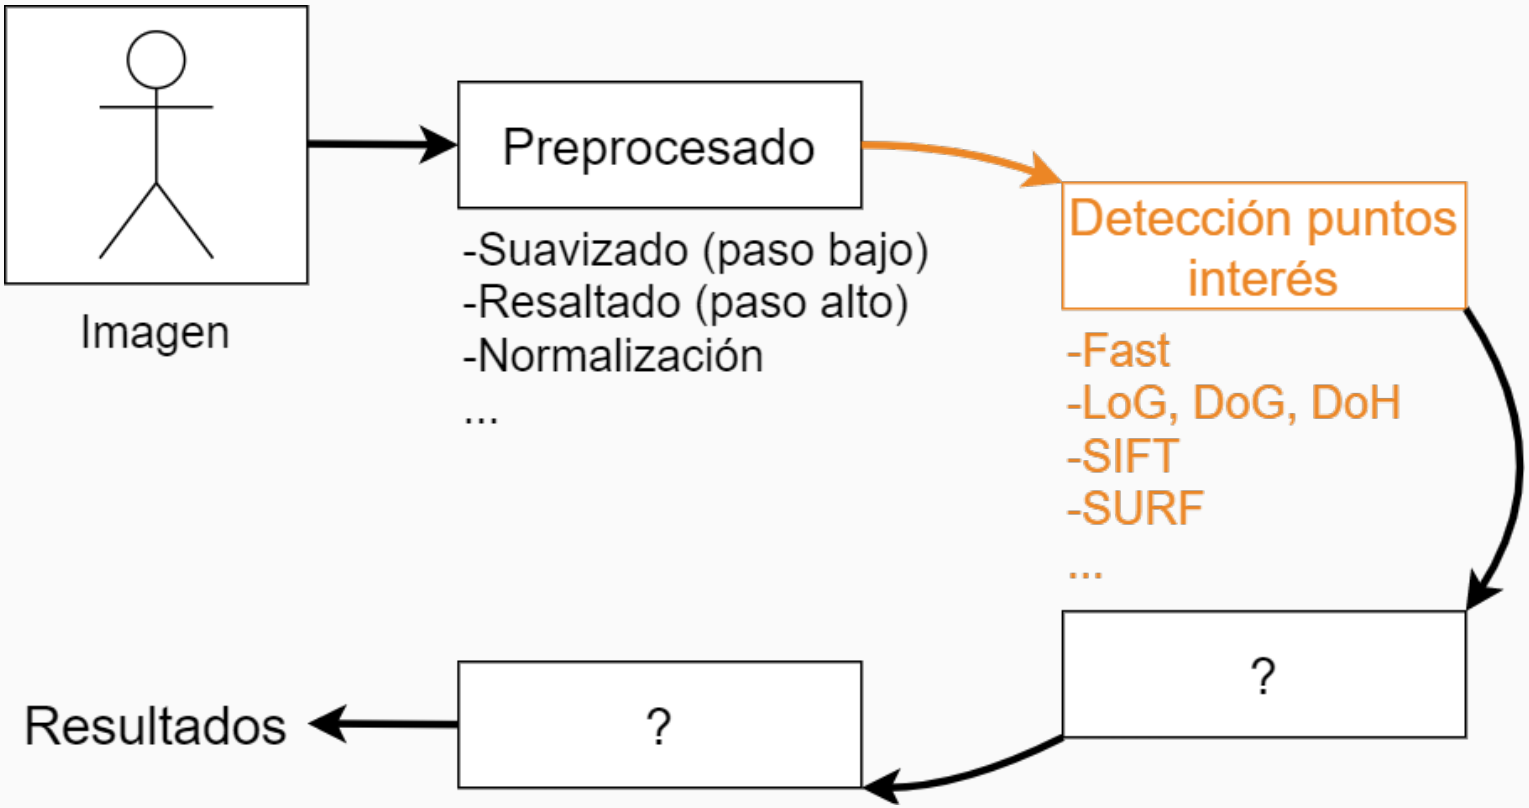

Ejemplos

- Correspondencia entre dos imágenes

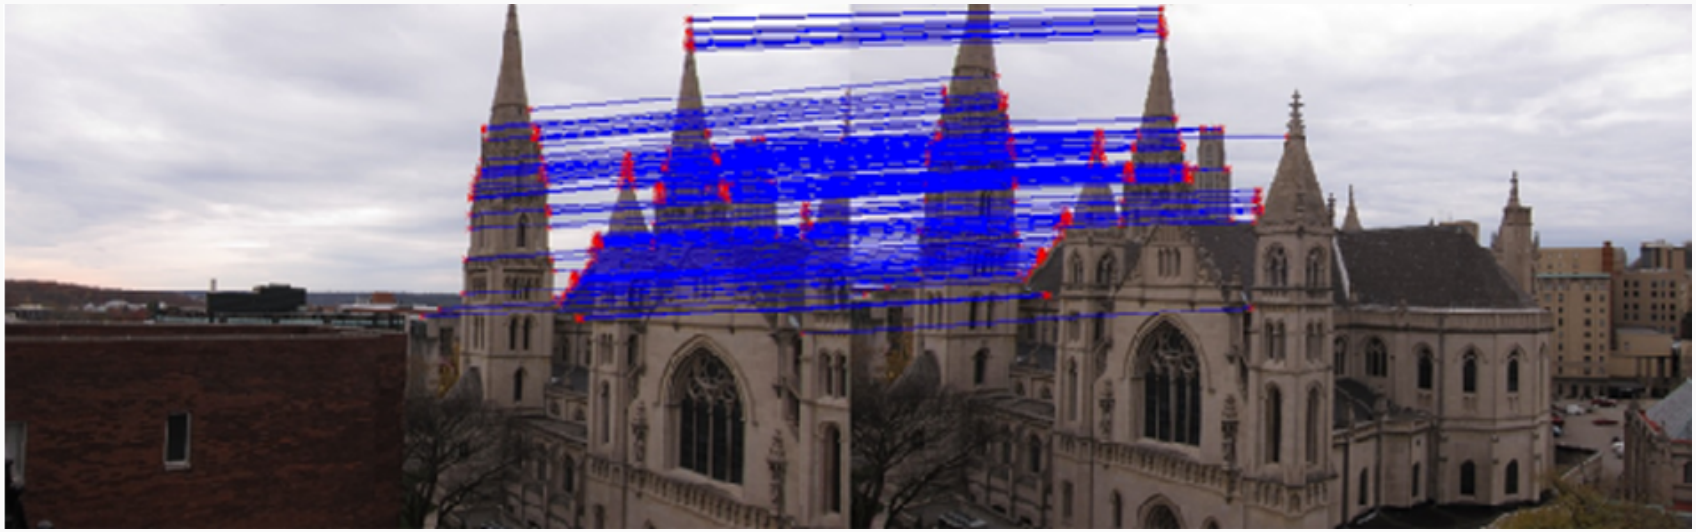

[1]

Ejemplos

- Creación de escenarios 3D

[1]

Correspondencia entre imágenes + Estimación de geometría

Ejemplos

- Reconocimiento de objetos

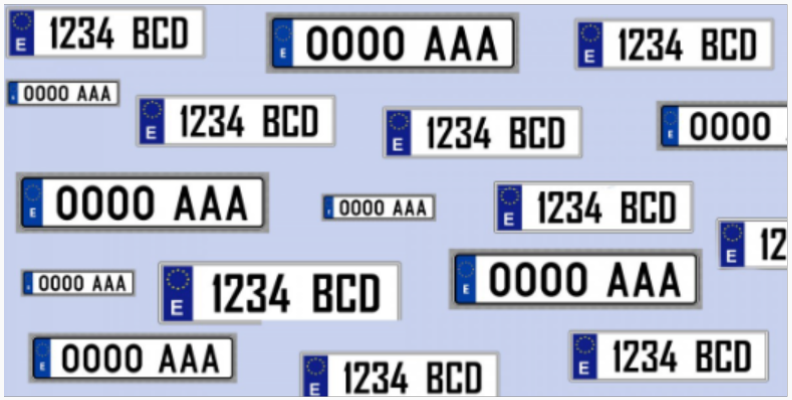

Ejemplos

- Diagnóstico comparativo

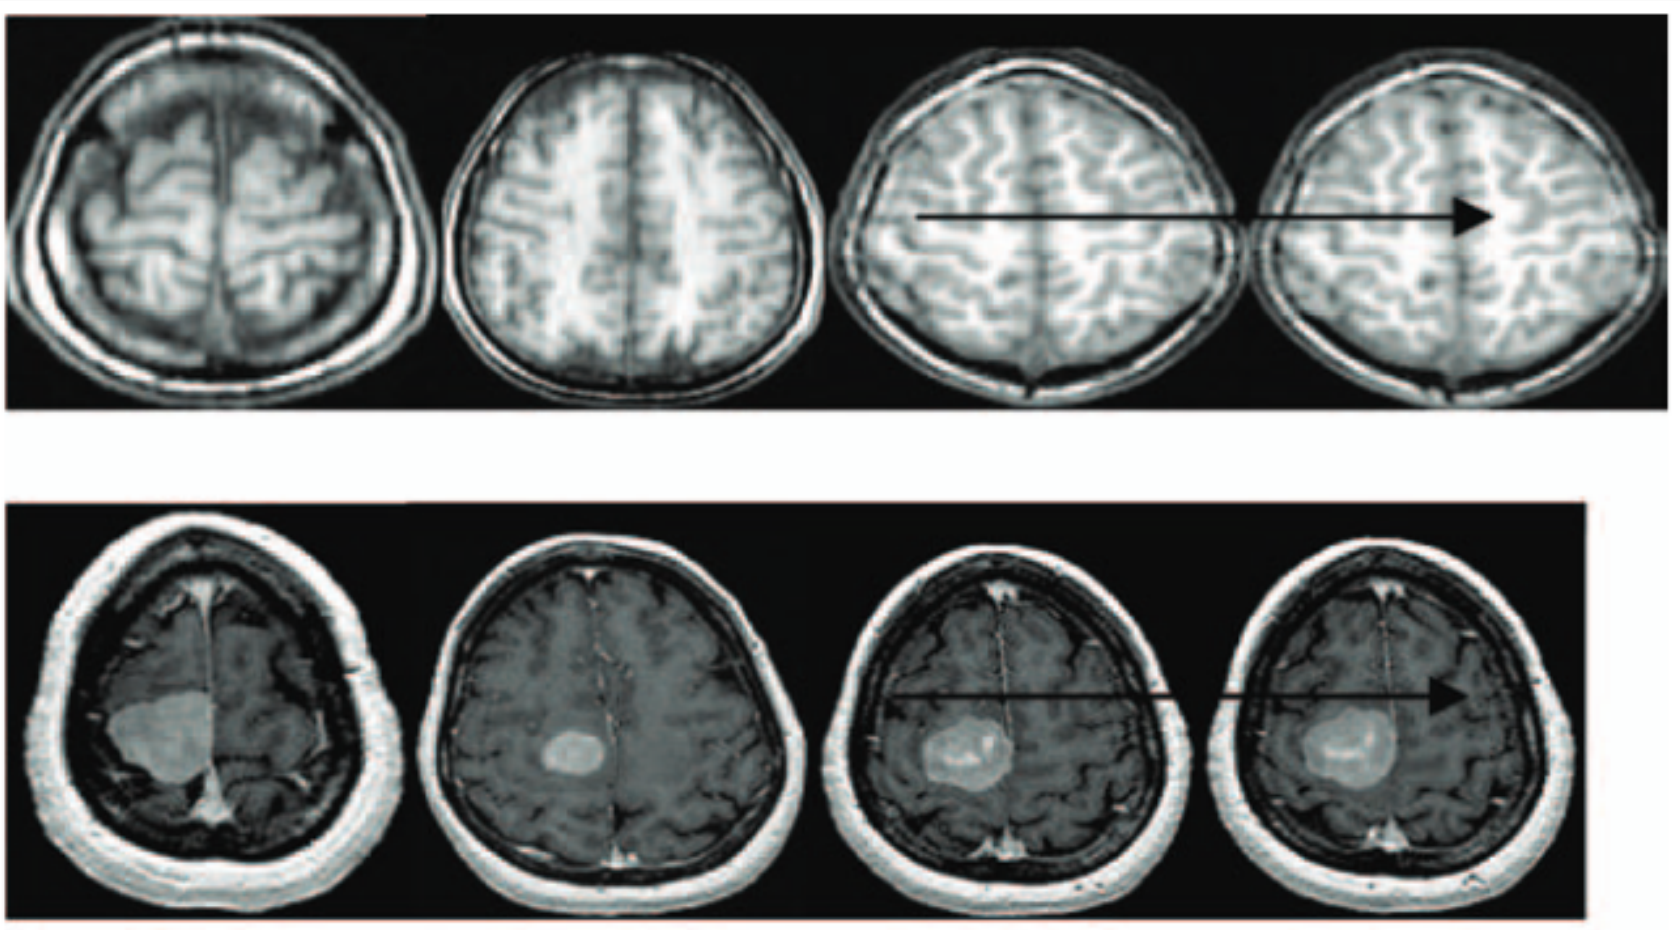

[2]

Notebook de ejemplos de descriptores

Los algoritmos que se explicarán a continuación pueden ser observados de manera práctica en el siguiente notebook.

- 02.06-Descriptores.ipynb

Algoritmos de detección de puntos de interés

Detección de estructuras de interés

Existen dos aproximaciones a la hora de reconocer qué puntos definen a una imagen:

- Detección de puntos o *keypoints*
- Detección de manchas o *blobs*

Detección de estructuras de interés

- Detección de puntos o *keypoints*:

Este conjunto de algoritmos tiene como objetivo mapear las distintas estructuras que componen una imagen. Para ello se realiza una combinación de los distintos puntos que caracterizan cada una de las partes de la imagen.

Una de las principales ventajas de esta aproximación es la sencillez y rapidez de cómputo.

Algoritmo FAST

El algoritmo Features from Accelerated Segment Test (FAST)[3] se centra en la detección de esquinas como puntos relevantes de una imagen.

Una de las principales ventajas de FAST respecto a otros algoritmos como Simultaneous Localization and Mapping (SLAM)[4] es su rápido cálculo, haciendo posible su uso en tiempo real.

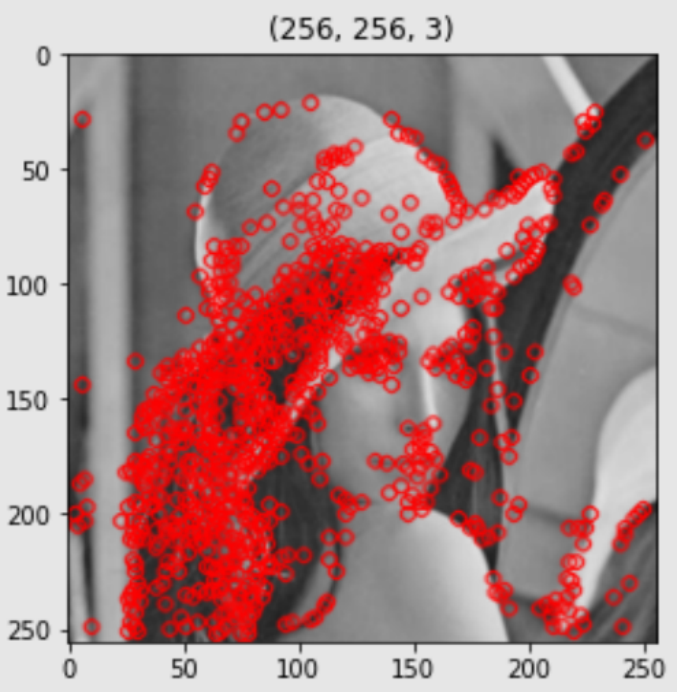

Algoritmo FAST

El algoritmo consta de cinco pasos diferenciados:

1. Se selecciona un píxel p de la imagen, que se define con su intensidad I_p.

Algoritmo FAST

El algoritmo consta de cinco pasos diferenciados:

1. Se selecciona un píxel p de la imagen, que se define con su intensidad I_p.
2. Se define un umbral t.

Algoritmo FAST

El algoritmo consta de cinco pasos diferenciados:

1. Se selecciona un píxel p de la imagen, que se define con su intensidad I_p.
2. Se define un valor de límite t.
3. Se dibuja un círculo de 16 píxeles alrededor del píxel.

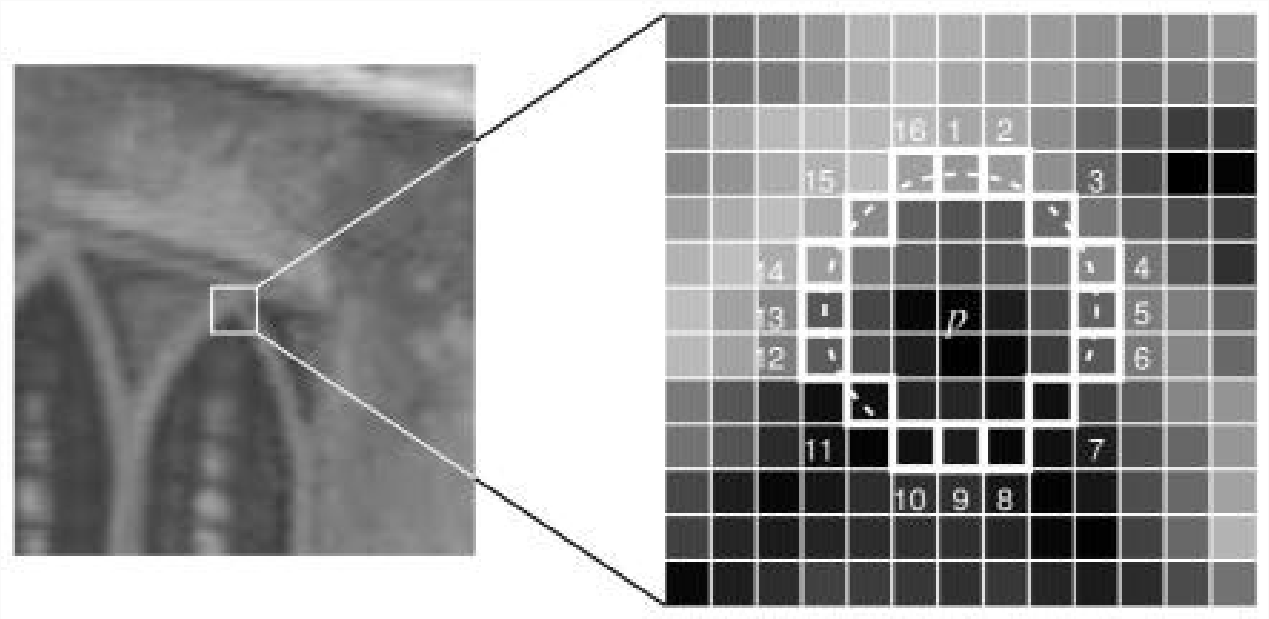

[5]

Algoritmo FAST

El algoritmo consta de cinco pasos diferenciados:

1. Se selecciona un píxel p de la imagen, que se define con su intensidad I_p.
2. Se define un valor de límite t.
3. Se escoge un píxel concreto p y se dibuja un círculo de 16 píxeles alrededor de él.
4. Se evalúa si el píxel p forma parte es un punto de interés.

Para ello se evalúa si al menos n (normalmente 12) de los píxeles del círculo son más brillantes que $I_p + t$ o menos que $I_p - t$. Si supera el umbral, p se considera un punto clave.

Algoritmo FAST

El algoritmo consta de cinco pasos diferenciados:

1. Se selecciona un píxel p de la imagen, que se define con su intensidad I_p.
2. Se define un valor de límite t.
3. Se escoge un píxel concreto p y se dibuja un círculo de 16 píxeles alrededor de él.
4. Se evalúa si el píxel p forma una esquina.
5. (Opcional) Supresión no máxima: existe un test de alta velocidad que sólo chequea los píxeles nº 1, 5, 9 y 13.

Esta variante produce un mayor número de falsos negativos, al rechazar muchos menos candidatos.

Detección de estructuras de interés

- Detección de manchas o *blobs*:

Los algoritmos de detención de manchas identifican regiones de la imagen según su posición relativa y forma.

Este tipo de estructuras se pueden identificar a través del uso de segundas derivadas parciales o segmentación.

¿Por qué usar segundas derivadas?

Cuando se deriva dos veces una función se pueden identificar las pendientes máximas y mínimas de una imagen donde la segunda derivada se vuelve cero. Es decir, se buscan regiones donde la intensidad cambia significativamente (bordes o transiciones).

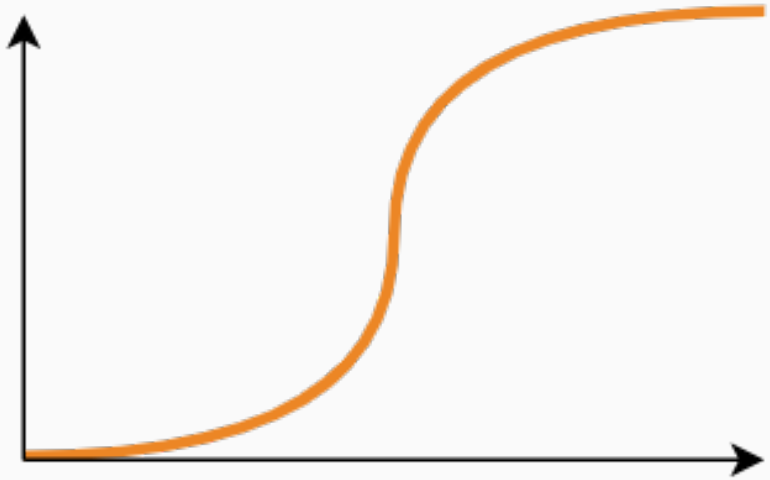

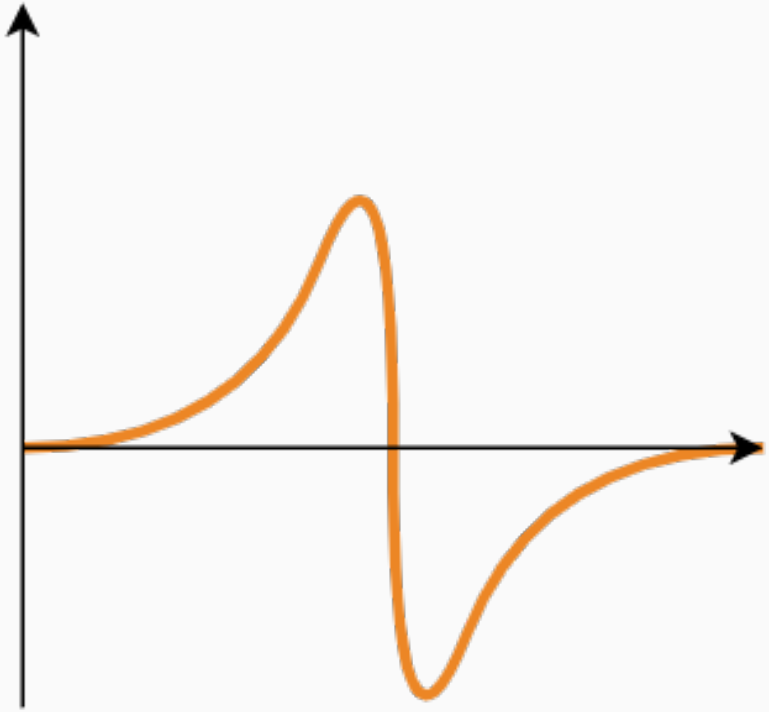

Identificar regiones con valor cero

La solución pasa por aplicar un filtrado de derivada de segundo orden a la imagen y observar qué regiones son mínimas. Dichas regiones indican cambios bruscos en la imagen.

Problema

Si la primera derivada de una imagen es 0, también los es la segunda derivada.

Esto hace que las regiones de intensidad constante tengan valor 0.

Identificar regiones con valor cero

Para identificar los bordes de la imagen se fuerza que la primera derivada sea mayor a un límite.

$$\left| \frac{dI(x)}{dx} \right| > Th \tag{1}$$

en el caso unidimensional.

$$\begin{aligned} |\nabla I(x,y)| &= \left(I_x^2(x,y) + I_y^2(x,y)\right)^{1/2} > Th \\ \tan\theta &= I_x(x,y)/I_y(x,y) \end{aligned} \tag{2}$$

en el caso bidimensional.

Identificar regiones con valor cero

Al mismo tiempo se busca que la segunda derivada tenga valor cero.

$$\frac{d^2 I(x)}{dx^2} = 0 \tag{3}$$

en el caso unidimensional.

$$\nabla^2 I(x, y) = I_{xx}(x, y) + I_{yy}(x, y) = 0 \tag{4}$$

en el caso bidimensional.

Laplaciano del Gaussiano para detectar blobs

El filtro del Laplaciano del Gaussiano equivale a la segunda derivada de la función Gaussiana.

Es por esto que, como hemos visto anteriormente, es utilizado para la detección de bordes de una imagen.

$$ker^{3x3} =$$

0	1	0
1	-4	1
0	1	0

Laplaciano del Gaussiano para detectar blobs

La pregunta ahora es ¿cómo utilizar el filtro Laplaciano para detectar blobs?

Los puntos máximos o mínimos corresponden con estructuras de interés para la escala del filtro en concreto (dada por el valor de σ).

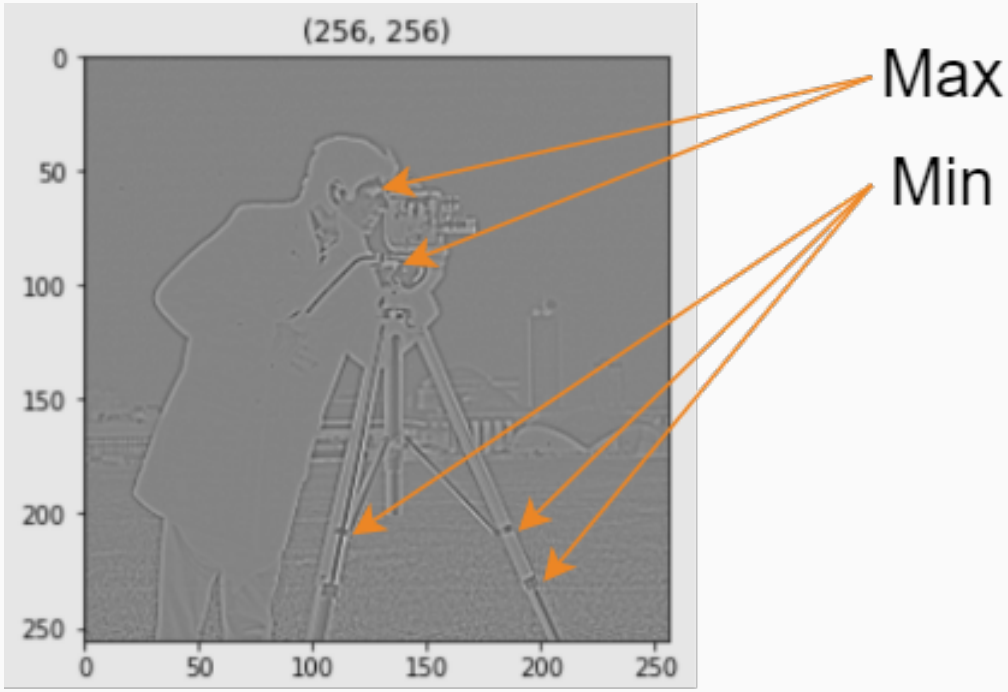

Laplaciano del Gaussiano para detectar blobs

A la hora de aplicar el Laplaciano del Gaussiano para detectar manchas, este se aplicar distintas veces a la misma imagen.

Lo que se pretende es detectar manchas a distintas escalas, para ello se utilizan filtrados con distintas desviaciones.

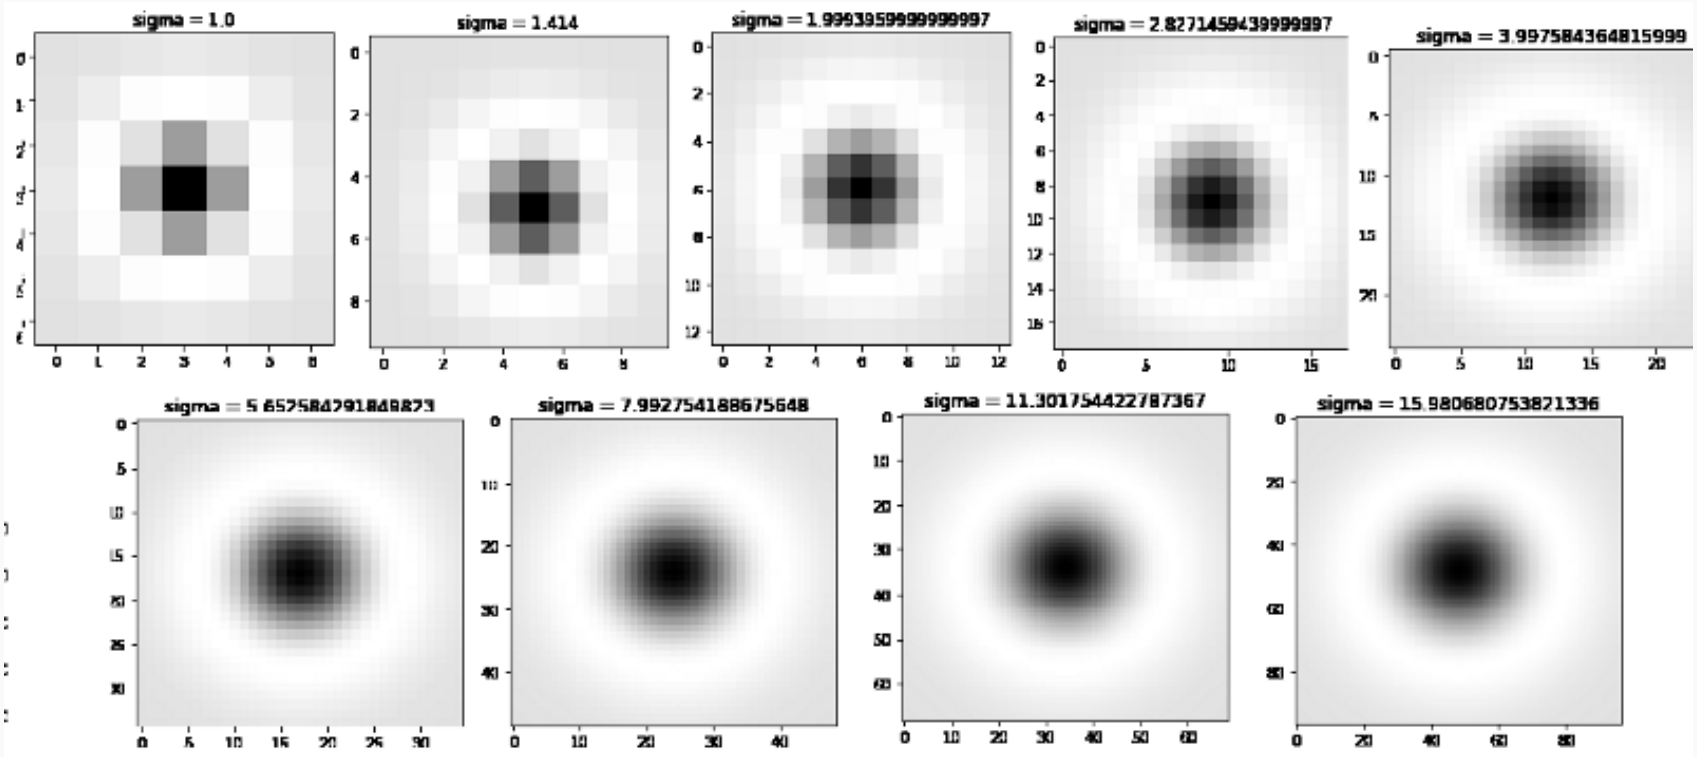

[6]

Diferencia de Gaussianas

Otro algoritmo para la detección de blobs es el de la diferencia entre Gaussianas. Este se basa en sustraer una imagen difuminada con un filtro Gaussiano de alta desviación, con otra imagen menos difuminada con un filtro Gaussiano.

De esta manera se aproxima la forma de una Laplaciana al mismo tiempo que se elimina el posible ruido.

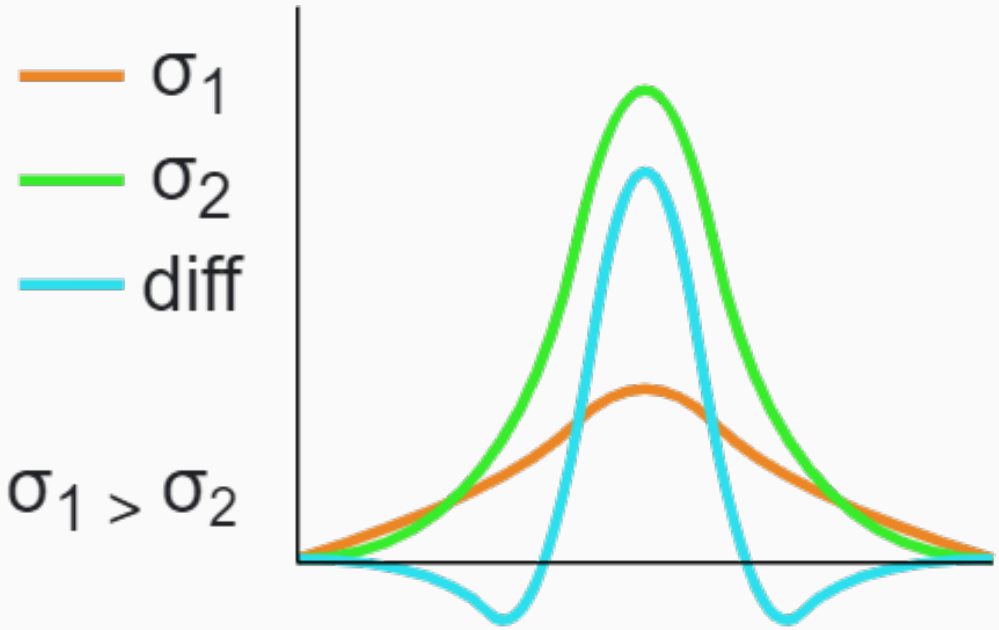

Diferencia de Gaussianas

Este algoritmo tiene como objetivo aproximar los resultados de la Laplaciana de Gaussianas. Para ello también aplica distintos filtrados para detectar estructuras a distintas escalas.

En comparación con el filtrado Laplaciano del Gaussiano, se consigue una mejor detección de manchas de mayor escala.

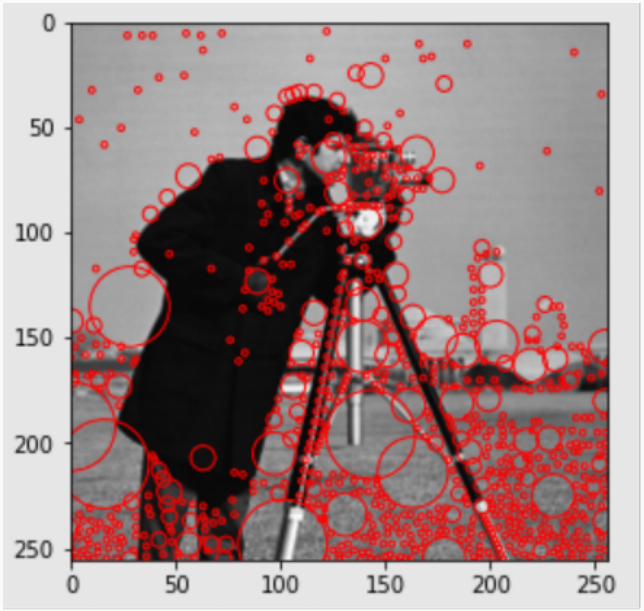

LoG

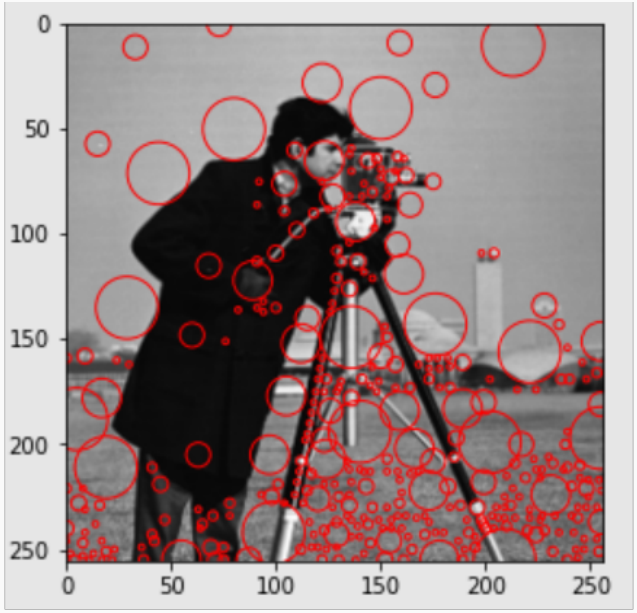

DoG

Determinante de la matriz Hessiana

El cálculo de blobs a través de la matriz Hessiana se realiza a través del cálculo del determinante de dicha matriz, el cual se define con:

$$\det H_{\text{norm}} = t^2 \left(L_{xx} L_{yy} - L_{xy}^2 \right) \tag{5}$$

donde H es la matriz Hessiana para cierta escala L.

La matriz Hessiana se calcula a través de la siguiente fórmula:

$$H = \begin{pmatrix} \frac{\partial^2 I}{\partial^2 x^2} & \frac{\partial^2 I}{\partial x \partial y} \\ \frac{\partial^2 I}{\partial y \partial x} & \frac{\partial^2 I}{\partial^2 y^2} \end{pmatrix} \tag{6}$$

para una imagen I.

Determinante de la matriz Hessiana

Existen trabajos[7, 8] que atribuyenmejores resultados que el Laplaciano del Gaussiano y la diferencia de Gaussianas.

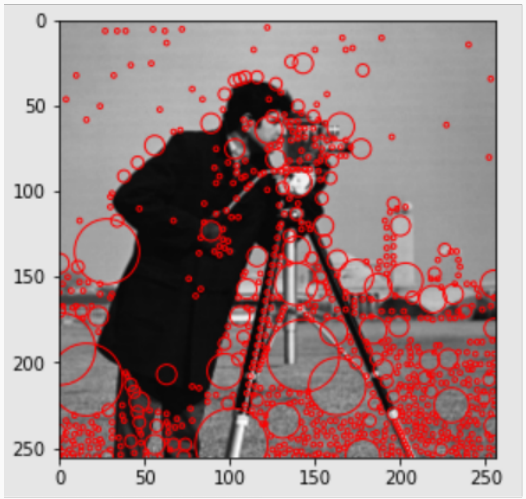

LoG

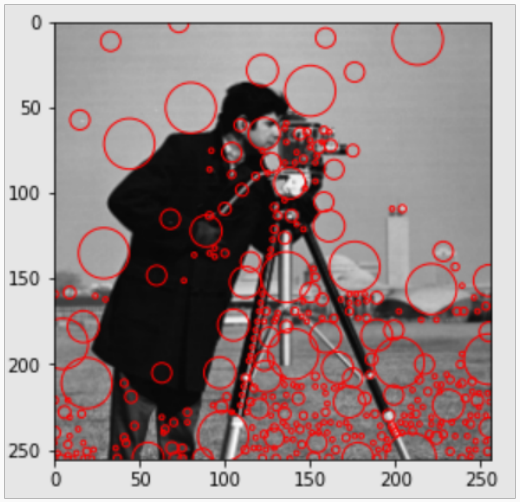

DoG

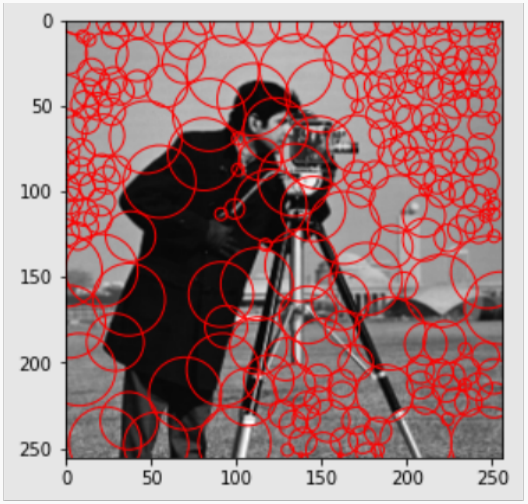

DoH

Referencias i

[1] Deva Ramanan 16-720 Computer Vision Spring 2017.
[Online; accessed August, 2022].

[2] Mana Tarjoman, Emad Fatemizadeh, and Kambiz Badie.
An implementation of a cbir system based on svm learning scheme.
Journal of Medical Engineering & Technology, 37(1):43–47, 2013.

[3] Deepak Geetha Viswanathan.
Features from accelerated segment test (fast).
In *Proceedings of the 10th workshop on image analysis for multimedia interactive services, London, UK*, pages 6–8, 2009.

[4] Hugh Durrant-Whyte and Tim Bailey.
Simultaneous localization and mapping: part i.
IEEE robotics & automation magazine, 13(2):99–110, 2006.

Referencias ii

[5] OpenCV.
Fast detector images.
[Online; accessed August, 2022].

[6] Nikhil Kumar (Projects Flix).
Sigma increment image.
[Online; accessed August, 2022].

[7] Tony Lindeberg.
Image matching using generalized scale-space interest points.
In *International conference on scale space and variational methods in computer vision*, pages 355–367. Springer, 2013.

[8] Tony Lindeberg.
Image matching using generalized scale-space interest points.
Journal of mathematical Imaging and Vision, 52(1):3–36, 2015.