

# Transfer learning

Visión por Computador, curso 2024-2025

---

Silvia Martín Suazo, [silvia.martin@u-tad.com](mailto:silvia.martin@u-tad.com)

6 de diciembre de 2024

U-tad | Centro Universitario de Tecnología y Arte Digital



Dentro del paradigma de las **redes neuronales artificiales** existen ciertas limitaciones que **lastran mucho** la aplicación de modelos.

- **Altos usos de memoria.**
- **Altos tiempos de espera en los entrenamientos.**
- **Dificultad a la hora de realizar “prueba y error”.**
- **Limitación en la disponibilidad de grandes datasets.**

Todos estos problemas son especialmente importantes tras los últimos avances producidos, en los que la tendencia es usar **modelos enormes** que requieren gran cantidad de **datos, tiempo y potencia de cómputo.**

# ¿Qué es el transfer learning?

El **transfer learning** es un método el cual permite **reutilizar** modelos ya diseñados, implementados y entrenados para **diferentes aplicaciones**.

La idea es reaprovechar el **aprendizaje** realizado previamente.

Las ventajas de utilizar el conjunto de técnicas de transfer learning son:


- **Convergencia más rápida y con mejores resultados.**
- **Reutilización de aprendizaje.**
- **Menor necesidad de recursos computacionales.**

# Transfer learning


En definitiva, el **transfer learning** consiste en reutilizar un modelo **previamente entrenado** para una **tarea específica** y reutilizarlo para otra **aplicación diferente**.

Por ejemplo, un modelo entrenado para **clasificar** imágenes de todo tipo puede ser reutilizado para clasificar **imágenes de perros y gatos**.

Modelo preentrenado



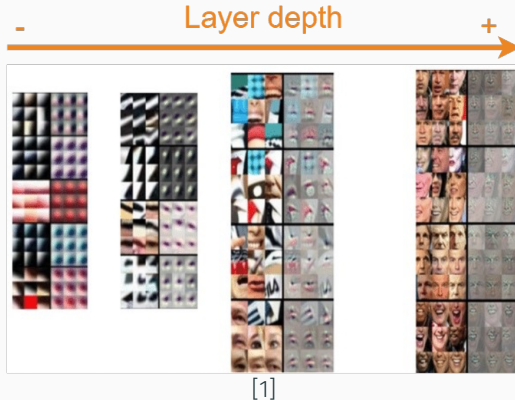
Transfer learning



# ¿Por qué es esto posible?


Como anteriormente se ha visto, la **estructura jerárquica** de las Convolutional Neural Network (CNN) permite a la red identificar estructuras **a distinto nivel**.

La información de las **primeras capas** (forma, color, bordes, texturas, etc.) es común a muchos tipos de problemas distintos.



# Transfer learning

Para llevar a cabo el transfer learning se realiza primero un “congelamiento” de las primeras capas convolucionales de la red. Esto impide que los parámetros de dichas capas **actualicen su valor**, impidiendo su entreno.



De esta manera, se permite que las características de mayor nivel sean aprendidas al nuevo entorno.


El nuevo entrenamiento se realiza utilizando completamente el nuevo dataset, y entrenando las nuevas capas.

Las primeras iteraciones del entrenamiento pueden ser sensibles debido a:

- Los pesos de las nuevas capas se inicializan aleatoriamente, por lo que su rendimiento será muy bajo.
- Las nuevas capas tardan en poder reutilizar las características extraídas anteriormente.

# Transfer learning

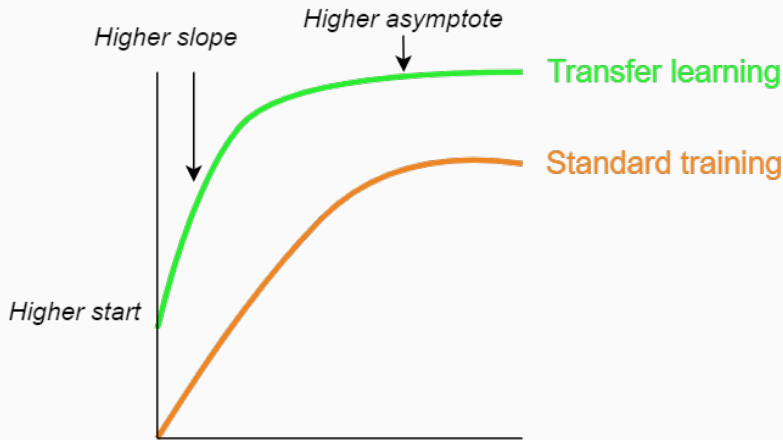
- Cuantas **menos capas** se congelen, el entrenamiento será más **lento** pero más **flexible**.
- Cuantas **más capas** se congelen, el entrenamiento será más **rápido** ya que reaprovechará el aprendizaje anterior, pero los resultados estarán **menos adaptados** a la nueva aplicación.






# Transfer learning: resultados

Gracias al **transfer learning** no sólo se consiguen **mejores resultados**, sino que también se consiguen de manera **más rápida**.



# Transfer learning: resultados

Gracias al **transfer learning** no sólo se consiguen **mejores resultados**, sino que también se consiguen de manera **más rápida**.



# Transfer learning: fine tuning

Una detalle que se puede observar a la hora de realizar transfer learning es que los pesos de las capas elegidas quedan **totalmente congelados**.

Esto se debe a lo siguiente:

- Cuando las nuevas capas están **inicializadas** generan muchos **errores**.
- Actualizar los pesos de las **capas congeladas** podría **desentrenarlas completamente**.
- Se intenta evitar la **inestabilidad** de una red no entrenada.
- Las capas congeladas tienen un **aprendizaje similar** al buscado, pero no es **exactamente el mismo**.

Es por esto que surge la técnica de **fine tuning**.

# Fine tuning

La idea principal del **fine tuning** es **proseguir el entrenamiento** del transfer learning, para ajustar de manera **delicada** los pesos de la red completa.


Para ello, se **descongelan** los pesos de toda la red, permitiendo su entrenamiento.

Con esto se pretenden los siguientes objetivos:

- Las capas previamente congeladas pueden **afinar su aprendizaje**, junto con las nuevas capas.
- El nuevo entrenamiento permitirá adaptar las **características genéricas** de las primeras capas a un propósito más específico.
- En ningún caso se pretende reentrenar estas capas, más bien se intenta **especializar** su función.

# Fine tuning

Los resultados tras el **fine tuning** permiten a la red **mejorar aún más** sus resultados, generando un resultado final óptimo.



La siguiente [guía de Tensorflow](#) contiene una explicación en profundidad de como realizar el [transfer learning](#) y [fine tuning](#) visto en las diapositivas.

## Hacia dónde van los modelos actuales

---

# El paradigma investigador actual

Durante los últimos años se ha observado que los modelos que mejores resultados obtienen son aquellos que consiguen tener mayor dimension.

Esto, como ya se ha visto conlleva ciertas problemáticas:

- Necesidad de cómputo para los entrenamientos.
- Necesidad de almacenamiento de datos.
- Problemas de modelos profundos.
- Disponibilidad de grandes datasets.



# ¿Cómo solventar la escasez de datos?

Una de las mayores limitaciones de este tipo de modelos es la necesidad de **grandes volúmenes de datos**, pero estos datos además necesitan estar **etiquetados**.


Estas dos necesidades son **incompatibles**, por limitaciones de **tiempo y esfuerzo humano**.


Existen distintas **alternativas** para evitar esto:

- **Data augmentation.**
- **Auto-etiquetado de imágenes.**
- **Self-supervised learning.**

# Aprendizaje self-supervised

El **aprendizaje auto-supervisado** o **self-supervised learning** consiste en realizar entrenamientos de redes neuronales haciendo usos de **datasets no etiquetados**. Para ello el aprendizaje se realiza utilizando los **datos de entrada** como principal mecanismo de aprendizaje.





Video Youtube

- [1] Samuel Wehrli, Corinna Hertweck, Mohammadreza Amirian, Stefan Glüge, and Thilo Stadelmann.  
**Bias, awareness, and ignorance in deep-learning-based face recognition.**  
*AI and Ethics*, 2(3):509–522, 2022.
- [2] Tensorflow.  
**Transfer learning results image.**  
[Online; accessed September, 2022].